

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ

«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Высшая школа бизнеса

Образовательная программа

«Бизнес-информатика»

VK EDUCATION

ОТЧЁТ ПО ПРОЕКТНОЙ ЗАДАЧЕ

**«Дообучение визуально-языковой модели для русскоязычного Visual Question Answering
на открытых данных VK»**

Выполнил:

Студент группы ББИ234 Литвак

Максим Евгеньевич

Москва 2026

Оглавление

Оглавление.....	2
Введение.....	4
Актуальность.....	5
Цель проекта.....	5
Задачи проекта.....	6
Объект и предмет исследования.....	7
Глава 1. Постановка задачи и обзор предметной области.....	7
1.1. Визуально-языковые модели.....	7
1.2. Особенности русскоязычного Visual Question Answering.....	8
1.3. Используемые данные.....	9
1.4. Выбор моделей.....	9
1.5. Использование метода LoRA.....	10
1.6. Постановка задачи.....	11
1.7. Оценка качества.....	12
Глава 2. Используемые данные.....	12
2.1. Источники данных.....	12
2.2. Набор данных GQA-ru.....	13
2.3. Использование GQA-ru в проекте.....	14
2.4. Предварительный анализ GQA-ru.....	15
2.5. Набор данных MMBench-ru.....	16
2.6. Подготовка данных.....	16
2.7. Ограничения данных.....	17
Глава 3. Модели и методика дообучения.....	18
3.1. Выбор базовых моделей.....	18
3.2. Выбор метода дообучения.....	19
3.3. Подготовка обучающих примеров.....	19
3.4. Конфигурации дообучения.....	20
3.5. Основные параметры обучения.....	22
3.6. Контроль процесса обучения.....	23
3.7. Объединение адаптера с базовой моделью.....	23
3.8. Общая схема методики.....	24
Глава 4. Методика оценки качества.....	25
4.1. Общий подход к оценке.....	25

4.2. Оценка на GQA-ru.....	25
4.3. Использование BERTScore.....	26
4.4. Оценка на MMBench-ru.....	27
4.5. Единые условия инференса.....	28
4.6. Полнота и корректность результатов.....	28
4.7. Анализ по категориям.....	29
4.8. Сравнение базовых и дообученных моделей.....	30
4.9. Ограничения методики оценки.....	30
4.10. Итоговая схема оценки.....	31
Глава 5. Результаты экспериментов.....	32
5.1. Общая характеристика проведённых экспериментов.....	32
5.2. Результаты обучения.....	33
5.3. Итоговые результаты на GQA-ru.....	33
5.4. Результаты SmolVLM на GQA-ru.....	35
5.5. Итоговые результаты на MMBench-ru.....	35
5.6. Перенос результатов дообучения.....	37
5.7. Результаты по категориям GQA-ru.....	37
5.8. Результаты по категориям MMBench-ru.....	38
5.9. Анализ ответов моделей.....	38
5.10. Выбор итоговых моделей.....	39
5.11. Основные выводы экспериментов.....	40
Глава 6. Реализация и публикация решения.....	41
6.1. Общая структура реализации.....	41
6.2. Используемые программные средства.....	42
6.3. Вычислительная среда.....	43
6.4. Реализация обучения.....	43
6.5. Реализация инференса и оценки.....	44
6.6. Хранение результатов.....	45
6.7. Объединение LoRA с базовой моделью.....	46
6.8. Публикация проекта на GitHub.....	46
6.9. Публикация моделей на Hugging Face.....	47
6.10. Воспроизводимость решения.....	48
6.11. Итоги реализации.....	48
Заключение.....	49

Использованные источники.....	50
Артефакты проекта.....	51

Введение

Современные визуально-языковые модели, или Vision-Language Models, позволяют одновременно обрабатывать изображения и текстовые запросы. Одним из направлений их применения является Visual Question Answering - формирование ответа на вопрос пользователя на основании содержания изображения. Такие модели могут использоваться для автоматического описания визуального контента, поиска объектов и атрибутов на изображениях, анализа карточек товаров, модерации контента и создания интеллектуальных ассистентов.

При этом качество большинства открытых визуально-языковых моделей в значительной степени зависит от языка входного запроса и обучающих данных. Модели, преимущественно обученные на англоязычных наборах, могут хуже понимать русскоязычные вопросы, формировать ответы на другом языке или допускать ошибки при распознавании объектов, их признаков и взаимного расположения.

В рамках проекта исследуются возможности адаптации открытых визуально-языковых моделей к русскоязычной задаче ответов на вопросы по изображениям. В качестве исходных архитектур выбраны Qwen2.5-VL-3B-Instruct и SmolVLM-Instruct. Для параметрически эффективного дообучения используется метод LoRA, который позволяет обучать небольшое количество дополнительных параметров без изменения всех весов исходной модели.

Обучение и оценка моделей проводятся на открытых данных VK из коллекции DeepVK. Набор GQA-ru используется для дообучения и проверки качества коротких открытых ответов, а MMBench-ru - для оценки переноса полученных результатов на задания с несколькими вариантами ответа. В проекте сравниваются базовые модели и несколько LoRA-конфигураций, а оценка проводится на полных доступных оценочных выборках обоих наборов данных.

Актуальность

Актуальность проекта обусловлена развитием мультимодальных систем искусственного интеллекта, способных работать одновременно с изображениями и естественным языком. Такие системы востребованы в поисковых сервисах, электронной коммерции, социальных сетях, системах модерации, средствах поддержки пользователей и приложениях для людей с нарушениями зрения.

Несмотря на значительный прогресс в области Vision-Language Models, русскоязычные визуально-языковые задачи остаются менее исследованными по сравнению с англоязычными. Многие открытые модели обучаются преимущественно на английском языке, из-за чего при работе с русскоязычными вопросами может снижаться точность ответов, нарушаться формат вывода или происходить переключение на английский язык.

Дополнительную актуальность представляет необходимость адаптации крупных моделей при ограниченных вычислительных ресурсах. Полное дообучение модели с несколькими миллиардами параметров требует значительного объема видеопамати и продолжительного времени. Использование LoRA позволяет заморозить базовые веса и обучать только дополнительные низкоранговые матрицы, что делает адаптацию визуально-языковых моделей доступной на пользовательском графическом процессоре.

Таким образом, проект актуален одновременно с исследовательской и практической точек зрения. Он позволяет определить, насколько параметрически эффективное дообучение на открытых русскоязычных данных VK улучшает качество ответов по изображениям и насколько полученные улучшения переносятся между различными VQA-бенчмарками.

Цель проекта

Цель проекта - повысить качество ответов визуально-языковых моделей на русскоязычные вопросы по изображениям с помощью параметрически эффективного дообучения LoRA на открытых данных VK и определить конфигурацию модели, показывающую наилучшие результаты на бенчмарках GQA-ru и MMBench-ru.

Задачи проекта

Для достижения поставленной цели необходимо решить следующие задачи:

1. Изучить структуру и особенности открытых русскоязычных наборов данных GQA-ru и MMBench-ru из коллекции DeepVK.
2. Провести разведочный анализ данных GQA-ru, включая анализ структуры выборок, длины вопросов и ответов, типов вопросов и распределения целевых ответов.
3. Подготовить данные в формате мультимодального диалога, содержащего изображение, русскоязычный вопрос и эталонный ответ.
4. Получить базовые результаты моделей Qwen2.5-VL-3B-Instruct и SmolVLM-Instruct без дополнительного обучения.
5. Реализовать параметрически эффективное дообучение моделей методом LoRA.
6. Обучить несколько LoRA-конфигураций, отличающихся объемом обучающей выборки, рангом LoRA, коэффициентом alpha и другими гиперпараметрами.
7. Провести сравнительную оценку базовых и дообученных моделей на полном оценочном сплите GQA-ru.
8. Проверить перенос качества моделей на набор MMBench-ru, который не используется при дообучении.
9. Рассчитать количественные метрики качества:
 - Exact Match для коротких открытых ответов на GQA-ru;
 - BERTScore F1 для оценки семантического сходства с эталонным ответом;
 - Ассурасу для заданий с вариантами ответа на MMBench-ru.
10. Проанализировать качество моделей по отдельным категориям вопросов, включая вопросы об объектах, атрибутах и отношениях между объектами.
11. Сохранить полные предсказания, метрики, конфигурации и журналы экспериментов для обеспечения воспроизводимости результатов.
12. Опубликовать лучшие обученные модели на платформе Hugging Face и предоставить код, результаты и инструкции по воспроизведению в публичном GitHub-репозитории.

В проекте фактически были обучены три LoRA-конфигурации для Qwen2.5-VL и одна конфигурация для SmolVLM, после чего шесть вариантов моделей были проверены на полных оценочных выборках GQA-ru и MMBench-ru.

Объект и предмет исследования

Объектом исследования являются визуально-языковые модели, предназначенные для формирования русскоязычных ответов на вопросы по изображениям.

В качестве конкретных реализаций рассматриваются базовые модели Qwen2.5-VL-3B-Instruct и SmolVLM-Instruct, а также их версии, адаптированные к русскоязычной задаче Visual Question Answering методом LoRA.

Предметом исследования является влияние параметрически эффективного дообучения LoRA, объёма обучающей выборки и выбранной конфигурации гиперпараметров на качество ответов визуально-языковых моделей на русскоязычные вопросы по изображениям.

К предмету исследования также относятся:

- изменение качества модели относительно базовой версии;
- способность модели формировать короткие ответы на русском языке;
- качество распознавания объектов, атрибутов и отношений между объектами;
- перенос результатов дообучения с открытых вопросов GQA-ru на задания с вариантами ответа MMBench-ru;
- различия между метриками точного совпадения и семантического сходства ответов;
- сравнительная эффективность моделей Qwen2.5-VL и SmolVLM при одинаковой постановке задачи.

Глава 1. Постановка задачи и обзор предметной области

1.1. Визуально-языковые модели

Современные системы искусственного интеллекта способны обрабатывать не только текст или изображения по отдельности, но и объединять информацию разных типов. К таким системам относятся визуально-языковые модели, или

Vision-Language Models. Они принимают на вход изображение и текстовый запрос, анализируют их совместно и формируют ответ на естественном языке.

В отличие от традиционных моделей компьютерного зрения, которые обычно решают отдельные задачи классификации или распознавания объектов, визуально-языковые модели позволяют работать с изображением в свободной форме. Пользователь может задать вопрос о содержании изображения, попросить определить объект, его цвет, расположение или связь с другими элементами сцены.

Одной из основных задач в данной области является Visual Question Answering – формирование ответа на вопрос по изображению. Для её решения модель должна правильно понять текст вопроса, определить необходимые объекты и признаки на изображении, а затем сформировать соответствующий ответ.

Визуально-языковые модели могут применяться в интеллектуальном поиске, электронной коммерции, социальных сетях, системах модерации, средствах поддержки пользователей и приложениях для людей с нарушениями зрения. Например, модель может отвечать на вопросы о фотографии товара, формировать краткое описание изображения или определять наличие определённого объекта.

1.2. Особенности русскоязычного Visual Question Answering

Большинство современных визуально-языковых моделей обучается преимущественно на англоязычных данных. Такие модели могут поддерживать русский язык, однако качество работы с русскоязычными вопросами часто оказывается ниже.

При обработке русскоязычных запросов модель может неправильно понять вопрос, перейти на английский язык, сформировать слишком длинный ответ или использовать формулировку, которая не соответствует ожидаемому формату. Для задач с короткими эталонными ответами это особенно важно. Например, вместо слова «красный» модель может написать полное предложение «Автомобиль на изображении красного цвета». Смысл ответа будет правильным, но при автоматической проверке он может быть признан ошибочным.

Поэтому в рамках проекта внимание уделялось не только пониманию изображений, но и формированию кратких ответов на русском языке. Модель должна была отвечать без дополнительных объяснений и сохранять формат, соответствующий используемым наборам данных.

1.3. Используемые данные

Проект выполнен на основе открытых данных VK, опубликованных организацией DeerVK. Согласно проектному заданию, необходимо было использовать открытые наборы данных для визуально-языкового моделирования, обучить собственную конфигурацию модели и провести её оценку на предложенных бенчмарках.

Основным набором данных для обучения являлся GQA-ru. Он содержит изображения, вопросы на русском языке и короткие эталонные ответы. Вопросы относятся к объектам, их атрибутам, взаимному расположению и общему содержанию изображений.

GQA-ru использовался как для дообучения моделей, так и для оценки качества открытых ответов. Большинство ответов в этом наборе состоит из одного или нескольких слов, поэтому задача была ориентирована на генерацию короткого ответа.

Для дополнительной оценки использовался MMBench-ru. В нём модель должна выбрать правильный вариант ответа из нескольких предложенных. Этот набор не использовался при обучении и позволял проверить, насколько полученные улучшения переносятся на другой формат мультимодальных заданий.

Итоговая оценка проводилась на всех доступных примерах выбранных оценочных частей: 12 216 заданий GQA-ru и 3 910 заданий MMBench-ru для каждого сравниваемого варианта модели.

1.4. Выбор моделей

В качестве основной модели была выбрана Qwen2.5-VL-3B-Instruct. Она поддерживает совместную обработку изображений и текста, подходит для

задачи Visual Question Answering и может быть запущена на доступном графическом процессоре.

Для дополнительного сравнения использовалась модель SmolVLM-Instruct. Она имеет меньший размер и более низкие требования к вычислительным ресурсам. Её использование позволило сравнить качество двух различных визуально-языковых архитектур.

Для каждой модели сначала были получены базовые результаты без дополнительного обучения. После этого модели были адаптированы к русскоязычной задаче с помощью метода LoRA.

Всего в итоговом сравнении участвовали:

- базовая модель Qwen2.5-VL;
- три дообученные конфигурации Qwen2.5-VL;
- базовая модель SmolVLM;
- дообученная конфигурация SmolVLM.

Такой подход позволил оценить влияние дообучения, объёма обучающих данных и выбранной базовой архитектуры на итоговое качество.

1.5. Использование метода LoRA

Полное дообучение визуально-языковой модели с несколькими миллиардами параметров требует большого объёма видеопамяти и значительных вычислительных ресурсов. Поэтому в проекте использовался метод LoRA, относящийся к параметрически эффективным способам дообучения.

При использовании LoRA основные веса исходной модели остаются замороженными. Обучаются только дополнительные параметры небольшого размера, которые изменяют работу отдельных слоёв модели. Благодаря этому снижаются требования к вычислительным ресурсам и ускоряется процесс обучения.

В проекте были обучены несколько конфигураций LoRA. Они различались количеством обучающих примеров и параметрами адаптера. Это позволило

проверить, приводит ли увеличение обучающей выборки и числа обучаемых параметров к повышению качества.

После завершения обучения лучшие LoRA-адаптеры были объединены с базовыми весами Qwen2.5-VL. В результате были получены полные версии моделей, которые можно использовать для инференса без отдельного подключения адаптера.

1.6. Постановка задачи

Основная задача проекта заключалась в адаптации визуально-языковых моделей к формированию коротких русскоязычных ответов на вопросы по изображениям.

Для решения задачи необходимо было:

- изучить структуру открытых данных VK;
- провести анализ вопросов, ответов и категорий заданий;
- получить базовые результаты выбранных моделей;
- подготовить данные для мультимодального обучения;
- обучить несколько LoRA-конфигураций;
- провести оценку моделей на одинаковых данных;
- сравнить базовые и дообученные варианты;
- проверить перенос качества на другой VQA-бенчмарк;
- определить наиболее успешную конфигурацию;
- сохранить результаты экспериментов и опубликовать лучшие модели.

Главный исследовательский вопрос проекта можно сформулировать следующим образом:

Позволяет ли дообучение методом LoRA на русскоязычных данных GQA-ru повысить качество визуально-языковой модели и сохраняется ли полученное улучшение при проверке на MMBench-ru?

Дополнительно исследовалось, как на результат влияют объём обучающей выборки, параметры LoRA и выбор базовой модели.

1.7. Оценка качества

Для оценки качества на GQA-ru использовалась метрика Exact Match. Она показывает долю ответов, которые полностью совпали с эталонными после нормализации текста. Перед сравнением удалялись лишние пробелы и знаки препинания, а текст приводился к единому регистру.

Недостаток Exact Match заключается в том, что она не учитывает правильные синонимы и близкие по смыслу ответы. Поэтому дополнительно применялась метрика BERTScore F1, оценивающая семантическое сходство ответа модели с эталоном.

Для MMBench-ru использовалась Ассигасу - доля правильно выбранных вариантов ответа.

Метрики GQA-ru и MMBench-ru оценивали разные форматы задач. GQA-ru требовал самостоятельно сформировать короткий ответ, а MMBench-ru - выбрать один из предложенных вариантов. По этой причине результаты двух бенчмарков рассматривались отдельно и напрямую не усреднялись.

Таким образом, в рамках проекта была поставлена задача не только обучить визуально-языковую модель, но и провести сравнительное исследование нескольких архитектур и конфигураций. Основное внимание уделялось повышению качества русскоязычных ответов, проверке результатов на двух бенчмарках и обеспечению воспроизводимости разработанного решения.

Глава 2. Используемые данные

2.1. Источники данных

В проекте использовались открытые русскоязычные наборы данных GQA-ru и MMBench-ru, опубликованные организацией DeepVK. Эти наборы входят в коллекцию VK, предназначенную для разработки и оценки визуально-языковых моделей.

Выбор данных соответствует условиям проектной задачи, согласно которым необходимо было обучить модель на открытых данных VK, описать способ их

использования и оценить качество полученного решения на предложенных бенчмарках.

Наборы данных выполняли разные функции:

- GQA-ru использовался для анализа данных, обучения моделей и оценки качества коротких открытых ответов;
- MMBench-ru использовался только для дополнительной оценки и проверки переноса качества на другой формат заданий.

Такое разделение позволило проверить не только способность модели адаптироваться к обучающим данным, но и устойчивость полученных результатов на независимом наборе.

2.2. Набор данных GQA-ru

GQA-ru представляет собой русскоязычную версию набора данных GQA для задачи Visual Question Answering. Он содержит изображения, вопросы на русском языке и эталонные ответы.

Данные разделены на две основные части:

- `train_balanced` - обучающая выборка;
- `testdev_balanced` - оценочная выборка.

Обучающая часть содержит 40 000 вопросов, связанных с 27 519 изображениями. Оценочная часть содержит 12 216 вопросов. При этом вопросы тестовой выборки относятся только к 398 изображениям. Следовательно, к одному тестовому изображению может быть задано большое количество различных вопросов.

Каждый пример включает:

- идентификатор вопроса;
- идентификатор изображения;
- изображение;
- вопрос на русском языке;
- короткий эталонный ответ;

- дополнительные сведения о типе вопроса.

Текстовые инструкции и изображения хранятся отдельно и связываются между собой по идентификатору изображения. При подготовке данных проверялось наличие соответствующего изображения для каждого вопроса, после чего вопрос, ответ и изображение объединялись в один обучающий пример.

Вопросы в GQA-ги охватывают несколько типов визуального анализа. Модель должна определять объекты, их свойства, цвета, количество и расположение, а также отношения между элементами изображения. Кроме того, в наборе присутствуют вопросы, предполагающие ответы «да» или «нет».

Примерами заданий могут быть следующие вопросы:

- «Какого цвета автомобиль?»;
- «Что находится слева от человека?»;
- «Есть ли на изображении дерево?»;
- «Сколько предметов находится на столе?»;
- «Где расположен объект?».

Ответы в большинстве случаев являются короткими и состоят из одного или нескольких слов. Поэтому GQA-ги хорошо подходит для обучения модели, предназначенной для кратких ответов без дополнительных пояснений.

2.3. Использование GQA-ги в проекте

Обучающая часть GQA-ги применялась для дообучения визуально-языковых моделей методом LoRA. В разных экспериментах использовались выборки объемом 5 000, 20 000 и 30 000 примеров для Qwen2.5-VL, а также 10 000 примеров для SmolVLM.

Использование нескольких объемов обучающих данных позволило проверить, как увеличение выборки влияет на качество модели. При формировании подвыборок использовался фиксированный параметр случайности, чтобы обеспечить воспроизводимость экспериментов.

Оценочная часть GQA-ru не использовалась при обучении. Она применялась для сравнения базовых и дообученных моделей. Финальная проверка проводилась на всех 12 216 доступных примерах testdev-сплита.

Для каждого примера модель получала изображение и вопрос, после чего должна была сформировать короткий текстовый ответ. Предсказание сравнивалось с эталонным ответом после нормализации регистра, пробелов и знаков препинания.

2.4. Предварительный анализ GQA-ru

Перед обучением была изучена структура данных, распределение вопросов и ответов, а также возможные проблемы качества.

Анализ показал, что вопросы являются относительно короткими. Средняя длина вопроса составляет около шести слов, а большинство эталонных ответов состоит из одного слова. Это подтвердило необходимость ограничивать длину генерации и требовать от модели краткий ответ.

В данных наблюдается неравномерное распределение ответов. Значительную часть выборки составляют частые ответы, например «да», «нет», «слева» и «справа». Поэтому модель может получать относительно высокую общую точность за счёт правильной обработки наиболее распространённых вариантов, оставаясь менее точной на редких объектах и признаках.

Среди вопросов представлены задания следующих категорий:

- вопросы об объектах;
- вопросы об атрибутах объектов;
- вопросы об отношениях между объектами;
- пространственные вопросы;
- вопросы на подтверждение;
- вопросы на сравнение.

Распределение категорий в обучающей и тестовой выборках различается. В тестовой части относительно велика доля вопросов об атрибутах, включая цвет,

размер, материал и другие свойства объектов. Поэтому качество распознавания визуальных признаков существенно влияет на итоговый результат.

Также была проверена целостность данных. Пустые вопросы и ответы не были обнаружены. Для используемых вопросов были доступны соответствующие изображения. Пропуски встречались преимущественно в дополнительных полях и не мешали формированию пар «изображение - вопрос - ответ».

2.5. Набор данных MMBench-ru

MMBench-ru представляет собой русскоязычный набор данных для комплексной оценки мультимодальных моделей. В проекте использовался dev-сплит, содержащий 3 910 заданий.

В отличие от GQA-ru, где модель самостоятельно формирует ответ, MMBench-ru использует формат с несколькими вариантами. Каждый пример содержит:

- изображение;
- вопрос;
- несколько вариантов ответа;
- обозначение правильного варианта;
- категорию задания.

Модель должна выбрать правильный ответ и вернуть соответствующую букву. После этого выбранный вариант сравнивается с эталоном.

MMBench-ru содержит более разнообразные задания, связанные с распознаванием объектов, описанием сцены, логическими выводами, пространственными отношениями и прогнозированием возможных событий.

В проекте данный набор не применялся для обучения. Все модели оценивались на одних и тех же 3 910 примерах, что позволило проверить, переносится ли эффект дообучения на данные другого формата.

2.6. Подготовка данных

Перед передачей данных модели выполнялась их предварительная обработка.

Для GQA-ги изображения связывались с вопросами по идентификатору. Из текстовых данных извлекались вопрос и короткий эталонный ответ. Строки с отсутствующим изображением, вопросом или ответом не допускались к обучению и оценке.

Каждый пример преобразовывался в мультимодальный диалог. В него включались изображение, текстовая инструкция и эталонный ответ. Инструкция требовала использовать изображение и сформировать только короткий ответ без объяснений.

Такая подготовка была необходима, поскольку исходная модель может генерировать развёрнутые предложения. Для автоматической оценки на GQA-ги требовался ответ, максимально близкий к краткому эталону.

При обработке MMBench-ги вопрос объединялся с вариантами ответа. Модель получала указание выбрать один вариант и вернуть его буквенное обозначение. Ответ дополнительно очищался, чтобы из него можно было корректно извлечь выбранную букву.

2.7. Ограничения данных

Используемые наборы имеют несколько особенностей, которые необходимо учитывать при интерпретации результатов.

Во-первых, в GQA-ги наблюдается дисбаланс ответов. Частые варианты встречаются значительно чаще редких, поэтому общая точность не полностью отражает качество модели на отдельных категориях.

Во-вторых, 12 216 вопросов оценочной части GQA-ги относятся только к 398 изображениям. Это означает, что отдельные вопросы не являются полностью независимыми. Ошибка в распознавании одного изображения может привести сразу к нескольким неправильным ответам.

В-третьих, часть правильных ответов может не засчитываться строгой метрикой Exact Match. Например, модель может использовать синоним, другую форму слова или более развёрнутую формулировку.

В-четвёртых, GQA-ги и MMBench-ги используют разные форматы заданий. Первый набор оценивает генерацию открытого ответа, а второй - выбор из предложенных вариантов. Поэтому значения метрик этих наборов нельзя напрямую сравнивать или объединять в один общий показатель.

Наконец, MMBench-ги использовался только для оценки. Небольшое изменение результата на нём не обязательно означает существенное улучшение способности модели к обобщению. Различия между близкими конфигурациями следует интерпретировать совместно с результатами GQA-ги и анализом отдельных категорий.

Таким образом, два выбранных набора данных дополняют друг друга. GQA-ги позволяет обучить модель формированию коротких русскоязычных ответов, а MMBench-ги - проверить её работу на более разнообразных заданиях с вариантами ответа.

Глава 3. Модели и методика дообучения

3.1. Выбор базовых моделей

В проекте использовались две визуально-языковые модели: Qwen2.5-VL-3B-Instruct и SmolVLM-Instruct. Обе модели способны совместно обрабатывать изображение и текстовый запрос, а затем формировать ответ на естественном языке.

Основной моделью была выбрана Qwen2.5-VL-3B-Instruct. Она содержит около 3,8 млрд параметров и поддерживает задачи анализа изображений, распознавания объектов и ответов на вопросы по визуальному содержанию. Выбор данной модели был обусловлен её сравнительно высоким качеством, поддержкой мультимодального входа и возможностью запуска на доступном графическом процессоре.

SmolVLM-Instruct использовалась как более компактная альтернатива. Её добавление позволило сравнить, насколько размер и исходная архитектура модели влияют на качество русскоязычных ответов после дообучения.

Для обеих моделей сначала были получены базовые результаты без дополнительного обучения. После этого модели были адаптированы к русскоязычной задаче Visual Question Answering.

3.2. Выбор метода дообучения

Полное дообучение визуально-языковой модели требует изменения всех её параметров. Для моделей, содержащих несколько миллиардов параметров, такой подход связан с высокими требованиями к видеопамяти, длительным временем обучения и большим размером сохраняемых результатов.

Поэтому в проекте применялся метод LoRA - Low-Rank Adaptation. Он относится к параметрически эффективным методам дообучения. При его использовании основные веса исходной модели остаются замороженными, а обучение затрагивает только небольшие дополнительные слои.

Преимуществами LoRA для данного проекта являлись:

- снижение требований к видеопамяти;
- сокращение количества обучаемых параметров;
- возможность проводить эксперименты на пользовательской видеокарте;
- меньший размер сохраняемого адаптера;
- возможность сравнивать несколько конфигураций на основе одной базовой модели;
- возможность объединить адаптер с базовыми весами после завершения обучения.

Таким образом, в рамках проекта не выполнялось обучение модели с нуля. Вместо этого уже обученные визуально-языковые модели адаптировались к формированию коротких русскоязычных ответов на данных GQA-ru.

3.3. Подготовка обучающих примеров

Каждый обучающий пример включал изображение, вопрос на русском языке и эталонный короткий ответ. Эти элементы преобразовывались в формат мультимодального диалога, соответствующий входным требованиям выбранной модели.

Модель получала изображение и инструкцию, в которой требовалось ответить на вопрос по его содержанию. Дополнительно указывалось, что ответ должен быть кратким и не содержать объяснений.

Такое ограничение было необходимо из-за особенностей GQA-ги. Большинство эталонных ответов состоит из одного или нескольких слов. Если модель формирует развёрнутое предложение, его смысл может быть правильным, но ответ не будет полностью совпадать с эталоном при автоматической проверке.

Для итоговой конфигурации Qwen использовалась русскоязычная инструкция следующего содержания:

«Ответь на вопрос, используя изображение. Дай только краткий ответ без объяснений».

В процессе подготовки также ограничивались длина текстовой последовательности и разрешение изображения. Это позволяло уменьшить расход видеопамати и сохранить возможность обучения на NVIDIA GeForce RTX 3080 с 12 ГБ видеопамати.

3.4. Конфигурации дообучения

В ходе проекта были обучены три варианта Qwen2.5-VL и один вариант SmolVLM. Конфигурации отличались объёмом обучающих данных и параметрами LoRA.

Первый вариант Qwen2.5-VL использовал 5 000 обучающих примеров. Он применялся как начальный эксперимент, позволяющий проверить работоспособность всего процесса и оценить влияние LoRA на качество модели.

Второй вариант Qwen2.5-VL обучался на 20 000 примерах. Для него был увеличен объём обучающей выборки и использована более ёмкая конфигурация LoRA. Обучение заняло около 4 часов 44 минут.

Третий вариант Qwen2.5-VL обучался на 30 000 примерах. В этой конфигурации LoRA дополнительно применялась к визуальным проекционным слоям модели, а инструкция была полностью переведена на русский язык. Обучение заняло около 8 часов 49 минут и завершилось со значением функции потерь 0,3462.

SmolVLM обучалась на 10 000 примерах. Для неё использовалась менее крупная конфигурация LoRA, соответствующая меньшему размеру базовой модели. Обучение заняло около 2 часов 21 минуты и завершилось со значением функции потерь 0,8804.

Общие характеристики конфигураций представлены ниже.

Таблица 3.1 - Конфигурации дообучения моделей

Модель	Количество обучающих примеров	Ранг LoRA	LoRA alpha
Qwen2.5-VL + LoRA №1	5 000	8	16
Qwen2.5-VL + LoRA №2	20 000	16	32
Qwen2.5-VL + LoRA №3	30 000	32	64
SmolVLM + LoRA	10 000	16	32

LoRA применялась к основным проекционным и полносвязным слоям трансформера. Для третьей конфигурации Qwen список обучаемых компонентов был расширен за счёт визуальных модулей. В результате в ней обучалось около 82,25 млн параметров, что составляло приблизительно 2,14% от общего числа параметров модели. В SmolVLM обучалось около 21,07 млн параметров, или 0,93% модели.

3.5. Основные параметры обучения

Для обеспечения сопоставимости результатов основные параметры обучения оставались одинаковыми для финальных конфигураций.

Каждая модель обучалась в течение одной эпохи. Размер батча на видеокарту составлял один пример. Для увеличения эффективного размера батча применялось накопление градиента в течение восьми шагов. Таким образом, обновление параметров выполнялось после обработки восьми примеров.

Скорость обучения для финальных конфигураций составляла 0,00001. Для начальной конфигурации Qwen использовалось значение 0,00002. В качестве оптимизатора применялся AdamW, а скорость обучения изменялась по косинусному расписанию.

Во всех запусках использовалось фиксированное значение случайного начального состояния, равное 42. Это обеспечивало воспроизводимое формирование обучающих подвыборок и более корректное сравнение экспериментов.

Для снижения потребления памяти применялись вычисления в формате BF16 и gradient checkpointing. При использовании gradient checkpointing промежуточные результаты сохраняются не для всех слоёв, а часть вычислений повторяется во время обратного прохода. Это увеличивает продолжительность обучения, но позволяет существенно уменьшить потребление видеопамати.

Основные параметры обучения:

- одна эпоха;
- размер батча на устройство - 1;
- накопление градиента - 8 шагов;
- эффективный размер батча - 8;
- оптимизатор AdamW;
- косинусное изменение скорости обучения;
- разогрев в течение первых 3% шагов;
- регуляризация весов - 0,01;
- LoRA dropout - 0,05;
- фиксированное случайное состояние - 42;

- использование BF16 и gradient checkpointing.

3.6. Контроль процесса обучения

Во время обучения отслеживалось изменение функции потерь. Снижение её значения показывало, что модель постепенно лучше воспроизводит эталонные ответы на обучающих примерах.

Промежуточные состояния модели регулярно сохранялись. Это позволяло продолжить работу после возможного прерывания обучения и уменьшало риск потери результатов длительного запуска.

Параметры экспериментов, обучающие метрики и сохранённые артефакты регистрировались с помощью MLflow и DagsHub. Для каждого запуска фиксировались используемая модель, параметры LoRA, размер обучающей выборки, скорость обучения, продолжительность запуска и итоговое значение функции потерь. Такой подход обеспечивал воспроизводимость и позволял сравнивать конфигурации между собой.

После обучения сохранялись:

- веса LoRA-адаптера;
- конфигурация адаптера;
- настройки процессора и токенизатора;
- параметры обучения;
- метрики выполнения.

3.7. Объединение адаптера с базовой моделью

LoRA-адаптер может использоваться отдельно от базовой модели. В таком случае для запуска необходимо сначала загрузить исходную модель, а затем подключить к ней соответствующий адаптер.

Для упрощения дальнейшего использования лучшие адаптеры Qwen2.5-VL были объединены с базовыми весами. После объединения была получена самостоятельная модель, содержащая все необходимые параметры и не требующая отдельного подключения LoRA.

Итоговые объединённые модели были опубликованы на платформе Hugging Face:

- Qwen2.5-VL с LoRA №2, показавшая лучший результат на GQA-ru;
- Qwen2.5-VL с LoRA №3, показавшая лучший результат на MMBench-ru.

При этом LoRA являлась методом дообучения, а опубликованные версии содержали уже полные объединённые веса модели.

3.8. Общая схема методики

Разработанная методика дообучения включала следующие этапы:

1. выбор базовой визуально-языковой модели;
2. получение результатов модели без дообучения;
3. подготовка пар «изображение - вопрос - ответ»;
4. преобразование данных в мультимодальный диалоговый формат;
5. подключение LoRA к выбранным слоям модели;
6. обучение адаптера на части GQA-ru;
7. сохранение промежуточных состояний и параметров запуска;
8. оценка дообученной модели на данных, не использованных при обучении;
9. сравнение нескольких конфигураций;
10. объединение лучших адаптеров с базовыми весами;
11. публикация итоговых моделей.

Использование нескольких моделей и конфигураций позволило проверить влияние объёма обучающей выборки, параметров LoRA и выбора базовой архитектуры. При этом увеличение количества данных и обучаемых параметров не рассматривалось как гарантированное улучшение: окончательный выбор модели осуществлялся на основании результатов независимой оценки.

Таким образом, выбранная методика обеспечила возможность адаптировать крупные визуально-языковые модели к русскоязычной задаче при ограниченных вычислительных ресурсах и получить несколько сопоставимых вариантов для последующего тестирования.

Глава 4. Методика оценки качества

4.1. Общий подход к оценке

После завершения обучения было проведено сравнение базовых и дообученных визуально-языковых моделей. Цель оценки заключалась в том, чтобы определить, насколько применение LoRA улучшило качество русскоязычных ответов по изображениям и сохраняется ли полученный эффект на заданиях другого формата.

В итоговом сравнении участвовали шесть вариантов моделей:

- базовая Qwen2.5-VL;
- три версии Qwen2.5-VL, дообученные методом LoRA;
- базовая SmolVLM;
- SmolVLM, дообученная методом LoRA.

Все модели проверялись на одинаковых оценочных данных и с одинаковыми принципами подготовки запросов. Это позволило сравнивать результаты напрямую и отделить влияние дообучения от различий в условиях тестирования.

Оценка проводилась на полных доступных выборках: 12 216 заданиях GQA-ru и 3 910 заданиях MMBench-ru для каждого варианта модели. В итоговых результатах отсутствовали пропущенные идентификаторы, дубликаты и необработанные ошибки инференса.

4.2. Оценка на GQA-ru

GQA-ru использовался для оценки способности модели самостоятельно формировать короткий ответ на вопрос по изображению. Для каждого примера модели передавались изображение и вопрос на русском языке. В инструкции дополнительно указывалось, что необходимо дать только краткий ответ без объяснений.

Длина генерации была ограничена, поскольку большинство эталонных ответов в GQA-ru состоит из одного или нескольких слов. Это снижало вероятность появления лишних пояснений и делало ответы моделей более сопоставимыми с эталонными значениями.

Основной метрикой для GQA-ru являлась Exact Match. Она показывает долю ответов модели, которые полностью совпали с эталонными после предварительной нормализации.

Перед сравнением выполнялись следующие преобразования:

- текст приводился к нижнему регистру;
- удалялись лишние пробелы;
- удалялись знаки препинания;
- ответы приводились к единому текстовому формату.

Например, ответы «Красный», «красный.» и « красный » после нормализации считались одинаковыми.

Преимуществом Exact Match является простота и однозначность интерпретации. Если значение метрики равно 0,50, это означает, что половина ответов модели полностью совпала с эталонами после нормализации.

При этом данная метрика является строгой. Она может не засчитать содержательно правильный ответ, если модель использовала синоним, другую форму слова или более подробную формулировку. Например, ответ «два человека» может не совпасть с эталоном «двое», несмотря на близкий смысл.

4.3. Использование BERTScore

Чтобы дополнить строгую метрику Exact Match, для GQA-ru также рассчитывался BERTScore F1. Эта метрика оценивает не полное текстовое совпадение, а семантическую близость ответа модели и эталонного ответа.

BERTScore позволяет учитывать ситуации, когда ответы отличаются по форме, но передают близкий смысл. Например, слова «автомобиль» и «машина» не совпадают полностью, однако являются семантически близкими.

Использование двух метрик позволило оценить качество с разных сторон:

- Exact Match показывал точность краткого ответа и соблюдение требуемого формата;
- BERTScore показывал смысловую близость ответа к эталону.

При интерпретации результатов основной метрикой оставался Exact Match, поскольку задача проекта была ориентирована именно на формирование коротких и точных ответов. BERTScore использовался как дополнительный показатель, позволяющий обнаружить случаи, в которых модель ошибалась только по формальному критерию. Используемые в проекте определения метрик и правила их расчёта приведены в описании репозитория.

4.4. Оценка на MMBench-ru

MMBench-ru использовался для проверки способности моделей переносить полученные навыки на другой формат мультимодальных заданий.

В отличие от GQA-ru, в MMBench-ru модель не должна самостоятельно формулировать открытый ответ. Для каждого вопроса ей предлагаются несколько вариантов, из которых необходимо выбрать один правильный.

В запрос включались:

- изображение;
- текст вопроса;
- варианты ответа;
- инструкция выбрать один из предложенных вариантов.

От модели требовалось вернуть буквенное обозначение выбранного ответа. После генерации результат очищался от лишнего текста, а затем из него извлекалась выбранная буква.

В качестве метрики использовалась Ассигасу - доля заданий, в которых модель выбрала правильный вариант.

MMBench-ru не использовался при дообучении моделей. Поэтому его применение позволяло оценить не только качество на данных, близких к обучающим, но и способность модели работать с другой структурой вопросов и ответов.

Если модель значительно улучшалась на GQA-ru, но не показывала аналогичного роста на MMBench-ru, это означало, что эффект дообучения мог

быть связан преимущественно со специализацией на формате коротких открытых ответов.

4.5. Единые условия инференса

Для обеспечения корректного сравнения все варианты одной архитектуры запускались в одинаковых условиях.

Для каждой модели использовались:

- одинаковые оценочные примеры;
- одинаковый порядок обработки данных;
- одинаковые инструкции;
- одинаковые ограничения длины ответа;
- детерминированная генерация без случайного выбора токенов;
- одинаковые правила нормализации и расчёта метрик.

При инференсе не применялось случайное семплирование. Модель каждый раз выбирала наиболее вероятный вариант продолжения. Такой подход уменьшал влияние случайности и позволял воспроизводить полученные ответы при повторном запуске в тех же условиях.

Для Qwen2.5-VL и SmolVLM использовались настройки обработки изображений, соответствующие возможностям каждой архитектуры и доступному объёму видеопамати. При этом внутри каждого семейства базовая и дообученная модели оценивались с одинаковыми параметрами.

4.6. Полнота и корректность результатов

Полная оценка нескольких визуально-языковых моделей занимает значительное время. Поэтому результаты сохранялись по мере прохождения выборки. Это позволяло продолжить вычисления после возможного прерывания без повторной обработки уже завершённых примеров.

После окончания инференса выполнялась проверка качества полученных файлов. Контролировались:

- общее количество обработанных примеров;

- количество уникальных идентификаторов;
- наличие повторяющихся строк;
- наличие пропущенных заданий;
- наличие лишних идентификаторов;
- ошибки загрузки изображений;
- ошибки генерации ответа;
- возможность корректно извлечь вариант ответа для MMBench-ru.

Только после прохождения этих проверок рассчитывались итоговые метрики и строилось сравнение моделей.

В итоговых таблицах для каждой модели было подтверждено наличие 12 216 результатов GQA-ru и 3 910 результатов MMBench-ru. Такой контроль был необходим, поскольку сравнение метрик на разном числе примеров могло привести к некорректным выводам.

4.7. Анализ по категориям

Помимо общей точности, качество моделей оценивалось по отдельным категориям вопросов.

Для GQA-ru рассматривались вопросы:

- об объектах;
- об атрибутах объектов;
- об отношениях между объектами;
- о категориях объектов;
- об общем содержании сцены.

Такой анализ позволял определить, в каких типах заданий дообучение давало наибольший эффект. Например, модель могла хорошо распознавать объекты и их цвета, но испытывать трудности при определении пространственных отношений.

Для MMBench-ru также рассчитывалась точность по категориям. Среди них рассматривались распознавание объектов, описание сцены, логические рассуждения, пространственные отношения и прогнозирование возможного развития ситуации.

Категориальный анализ был необходим, поскольку одинаковая общая метрика может скрывать разные особенности моделей. Одна модель может быть сильнее в распознавании объектов, а другая - в логических заданиях. Поэтому итоговый выбор конфигурации не должен основываться только на одном агрегированном показателе.

4.8. Сравнение базовых и дообученных моделей

Для оценки влияния LoRA результаты каждой дообученной модели сравнивались с результатами соответствующей базовой архитектуры.

Основными показателями являлись:

- изменение Exact Match на GQA-ru;
- изменение BERTScore F1 на GQA-ru;
- изменение Accuracy на MMBench-ru;
- изменение точности по отдельным категориям.

Особое внимание уделялось не только абсолютному значению метрики, но и разнице относительно базовой модели. Такой подход позволял определить, какой эффект был получен именно за счёт дообучения.

Для Qwen2.5-VL сравнивались три LoRA-конфигурации. Это позволило проверить, приводит ли увеличение объёма обучающих данных и количества обучаемых параметров к последовательному росту качества.

Однако более крупная конфигурация не считалась автоматически лучшей. Окончательный выбор модели выполнялся на основании независимой оценки. В результате одна конфигурация могла показывать лучший результат на GQA-ru, а другая - на MMBench-ru.

4.9. Ограничения методики оценки

При интерпретации результатов учитывались ограничения используемой методики.

Во-первых, Exact Match не учитывает все возможные корректные формулировки. Поэтому небольшая часть содержательно правильных ответов могла быть отнесена к ошибочным.

Во-вторых, BERTScore отражает семантическую близость, но не всегда позволяет определить фактическую правильность ответа. Семантически похожие слова могут обозначать разные объекты или признаки.

В-третьих, значительная часть вопросов GQA-ru относится к одним и тем же изображениям. Оценочная выборка содержит 12 216 вопросов, но только 398 уникальных изображений. Поэтому отдельные ответы не являются полностью независимыми. Ошибка в понимании одной сцены может привести сразу к нескольким неправильным ответам.

В-четвёртых, GQA-ru и MMBench-ru оценивают разные навыки. GQA-ru проверяет свободную генерацию ответа, а MMBench-ru - выбор из готовых вариантов. По этой причине их метрики не объединялись в один общий показатель.

В-пятых, небольшие различия на MMBench-ru следует интерпретировать осторожно. Если результаты моделей отличаются менее чем на один процентный пункт, этого недостаточно для вывода о существенном превосходстве одной конфигурации. Такое различие может соответствовать нескольким десяткам заданий и не обязательно свидетельствует о принципиальном улучшении модели.

4.10. Итоговая схема оценки

Методика оценки качества включала следующие этапы:

1. подготовку одинаковых оценочных данных для всех моделей;
2. формирование запросов в соответствии с форматом каждого датасета;
3. получение предсказаний базовых и дообученных моделей;
4. сохранение результатов по мере прохождения выборки;
5. проверку полноты и корректности предсказаний;
6. нормализацию текстовых ответов;
7. расчёт Exact Match и BERTScore F1 для GQA-ru;

8. извлечение выбранного варианта и расчёт Accurasy для MMBench-ru;
9. расчёт точности по отдельным категориям;
10. сравнение моделей с соответствующими базовыми версиями;
11. анализ ограничений и возможных причин ошибок.

Таким образом, оценка проводилась не по отдельной небольшой подвыборке, а на всех доступных примерах выбранных оценочных сплитов. Использование двух бенчмарков и нескольких метрик позволило оценить как качество коротких русскоязычных ответов, так и способность моделей переносить полученные навыки на задания другого формата.

Глава 5. Результаты экспериментов

5.1. Общая характеристика проведённых экспериментов

В ходе проекта были обучены и оценены несколько вариантов визуально-языковых моделей. Основное сравнение проводилось между исходными моделями Qwen2.5-VL и SmolVLM и их версиями, дообученными методом LoRA на русскоязычном наборе GQA-ru.

Всего в итоговой оценке участвовали шесть вариантов:

- базовая Qwen2.5-VL;
- Qwen2.5-VL с LoRA №1;
- Qwen2.5-VL с LoRA №2;
- Qwen2.5-VL с LoRA №3;
- базовая SmolVLM;
- SmolVLM с LoRA.

Каждая модель была проверена на 12 216 заданиях GQA-ru и 3 910 заданиях MMBench-ru. Для всех вариантов использовались одинаковые оценочные данные и правила расчёта метрик. Проверка итоговых результатов не выявила пропущенных заданий, повторяющихся идентификаторов или необработанных ошибок инференса.

5.2. Результаты обучения

Все выбранные конфигурации успешно завершили одну эпоху обучения. В процессе обучения значение функции потерь постепенно снижалось, что указывало на адаптацию моделей к структуре русскоязычных вопросов и коротких ответов GQA-ru.

Увеличение объёма обучающей выборки и числа параметров LoRA приводило к росту продолжительности обучения. Вторая конфигурация Qwen2.5-VL, обученная на 20 000 примерах, потребовала около 4 часов 44 минут. Итоговое значение функции потерь составило приблизительно 0,39.

Третья конфигурация обучалась на 30 000 примерах и потребовала около 8 часов 49 минут. Она показала более низкое итоговое значение функции потерь по сравнению со второй конфигурацией. Однако уменьшение функции потерь на обучающих данных само по себе не гарантировало более высокого результата на оценочной выборке.

Первые проверки на выборке из 1 000 заданий показали заметное улучшение Qwen2.5-VL после подключения LoRA: Exact Match увеличился с 32,1% до 56,5%. При этом LoRA дала правильный ответ в 273 случаях, в которых базовая модель ошиблась, тогда как обратная ситуация наблюдалась только в 29 случаях.

После положительных результатов предварительной проверки оценка была проведена на полном доступном сплите GQA-ru.

5.3. Итоговые результаты на GQA-ru

В таблице 5.1 представлены итоговые результаты всех моделей на 12 216 заданиях GQA-ru.

Таблица 5.1 - Результаты моделей на GQA-ru

Модель	Exact Match	BERTScore F1

Qwen2.5-VL + LoRA №2	0,5372	0,9065
Qwen2.5-VL + LoRA №3	0,5352	0,9055
Qwen2.5-VL + LoRA №1	0,5006	0,8981
Qwen2.5-VL, базовая	0,3198	0,8064
SmolVLM + LoRA	0,2918	0,8511
SmolVLM, базовая	0,2028	0,6790

Наилучший результат показала Qwen2.5-VL с LoRA №2. Значение Exact Match составило 0,5372, то есть модель сформировала полностью правильный нормализованный ответ приблизительно для 53,7% заданий.

Базовая Qwen2.5-VL получила Exact Match 0,3198. Следовательно, применение LoRA №2 повысило результат на 21,74 процентного пункта. BERTScore F1 увеличился с 0,8064 до 0,9065, что также свидетельствует о повышении смысловой близости ответов к эталонным значениям.

Первая конфигурация LoRA, обученная на меньшем количестве примеров, получила Exact Match 0,5006. Она существенно превзошла базовую модель, однако уступила более крупным конфигурациям. Это показывает, что даже сравнительно небольшая обучающая выборка позволила заметно адаптировать модел к русскоязычной задаче.

Вторая и третья конфигурации показали практически одинаковый результат. Разница Exact Match между ними составила около 0,2 процентного пункта. При

этом третья конфигурация использовала больше обучающих примеров и более ёмкий адаптер, но не превзошла вторую.

Следовательно, увеличение объёма обучения с 20 000 до 30 000 примеров не обеспечило дальнейшего роста качества на GQA-ru. В рассматриваемых условиях вторая конфигурация оказалась более эффективной: она показала немного более высокий результат при меньших затратах времени на обучение.

5.4. Результаты SmolVLM на GQA-ru

Базовая SmolVLM показала Exact Match 0,2028 и BERTScore F1 0,6790. После дообучения Exact Match увеличился до 0,2918, а BERTScore F1 - до 0,8511.

Таким образом, LoRA повысила Exact Match SmolVLM приблизительно на 8,9 процентного пункта. Особенно заметно вырос BERTScore, что говорит о повышении смысловой близости ответов модели к эталонам.

Несмотря на положительный эффект дообучения, SmolVLM не достигла качества базовой Qwen2.5-VL по Exact Match. Дообученная SmolVLM получила результат 0,2918, тогда как базовая Qwen2.5-VL - 0,3198.

Полученный результат показывает, что LoRA способна значительно улучшить более компактную модель, однако исходная архитектура и возможности базовой модели продолжают существенно влиять на итоговое качество. Для рассматриваемой задачи Qwen2.5-VL оказалась более подходящей архитектурой.

5.5. Итоговые результаты на MMBench-ru

В таблице 5.2 представлены результаты моделей на 3 910 заданиях MMBench-ru.

Таблица 5.2 - Результаты моделей на MMBench-ru

Модель	Accuracy
--------	----------

Qwen2.5-VL + LoRA №3	0,8061
Qwen2.5-VL + LoRA №2	0,8033
Qwen2.5-VL, базовая	0,7992
Qwen2.5-VL + LoRA №1	0,7980
SmolVLM, базовая	0,3734
SmolVLM + LoRA	0,3655

Наилучший результат на MMBench-ru показала Qwen2.5-VL с LoRA №3. Ассигасу составила 0,8061. Вторая конфигурация получила результат 0,8033, а базовая Qwen2.5-VL - 0,7992.

В отличие от GQA-ru, прирост после дообучения оказался небольшим. LoRA №3 превзошла базовую модель приблизительно на 0,69 процентного пункта, а LoRA №2 - на 0,41 процентного пункта.

Первая конфигурация LoRA показала результат немного ниже базовой модели. Это означает, что улучшение качества на GQA-ru не гарантировало аналогичного улучшения на MMBench-ru.

Различия между вариантами Qwen2.5-VL на MMBench-ru составляют менее одного процентного пункта. Поэтому результат LoRA №3 нельзя интерпретировать как значительное превосходство над второй конфигурацией или базовой моделью. Для подтверждения такого различия потребовалась бы дополнительная статистическая проверка или оценка на другом независимом наборе данных.

5.6. Перенос результатов дообучения

Сравнение двух бенчмарков показало, что эффект LoRA зависит от формата задачи.

На GQA-ru дообученные варианты Qwen2.5-VL значительно превосходили базовую модель. Это объясняется тем, что модель обучалась на данных того же типа: изображение, русскоязычный вопрос и короткий открытый ответ.

На MMBench-ru модель должна была выбрать один вариант из нескольких предложенных. Такой формат не использовался при дообучении. Поэтому улучшение оказалось значительно менее выраженным.

Полученные результаты показывают, что LoRA прежде всего адаптировала Qwen2.5-VL к следующим особенностям GQA-ru:

- русскоязычным формулировкам вопросов;
- генерации коротких ответов;
- частым категориям и ответам обучающей выборки;
- структуре заданий с открытым ответом.

При этом общие мультимодальные способности модели изменились незначительно. Это подтверждается близкими результатами базовой и дообученных версий Qwen2.5-VL на MMBench-ru.

Для SmolVLM перенос оказался ещё слабее. Несмотря на рост качества на GQA-ru, Accurasy на MMBench-ru снизилась с 0,3734 до 0,3655. Следовательно, дообучение SmolVLM привело к специализации на GQA-ru, но не повысило качество на заданиях другого формата.

5.7. Результаты по категориям GQA-ru

Дополнительно была проведена оценка качества по категориям вопросов. Лучший вариант Qwen2.5-VL с LoRA №2 показал следующие результаты:

- вопросы об объектах - 0,8305;
- вопросы об атрибутах - 0,6287;
- вопросы об отношениях между объектами - 0,4304.

Наиболее высокое качество модель показала при определении объектов. В эту категорию входят вопросы о том, какой предмет, животное или человек присутствует на изображении.

Более сложными оказались вопросы об атрибутах. Для ответа на них необходимо определить цвет, размер, материал, состояние или другое свойство объекта.

Самой сложной категорией стали отношения между объектами. Такие задания требуют учитывать сразу несколько элементов изображения и определять их взаимное расположение или смысловую связь. К ним относятся вопросы о том, что находится слева, справа, перед объектом или позади него.

Таким образом, модель лучше справлялась с распознаванием отдельных объектов, чем с многоэтапным анализом визуальной сцены.

5.8. Результаты по категориям MMBench-ru

На MMBench-ru наиболее сильными категориями для моделей Qwen2.5-VL оказались задания, связанные с определением объектов и описанием общего содержания сцены.

Более низкое качество наблюдалось в заданиях на пространственные отношения и прогнозирование возможного развития ситуации. Такие вопросы требуют не только распознать видимые элементы, но и выполнить дополнительное рассуждение на основании изображения.

Данный результат согласуется с категориальным анализом GQA-ru. В обоих наборах модели лучше справлялись с прямым распознаванием объектов и атрибутов, чем с пространственными связями и более сложными логическими выводами.

5.9. Анализ ответов моделей

Просмотр отдельных предсказаний показал, что после дообучения Qwen2.5-VL стала чаще формировать ответы на русском языке и лучше соблюдать краткий формат.

Базовая модель в некоторых случаях:

- отвечала на английском языке;
- формировала полное предложение вместо одного слова;
- добавляла пояснение;
- повторяла часть вопроса;
- использовала ответ, близкий по смыслу, но не совпадающий с эталоном.

После применения LoRA количество таких случаев уменьшилось. Модель чаще возвращала одно слово или короткую фразу, соответствующую структуре GQA-ru.

При этом сохранились несколько типов ошибок:

- неправильное определение пространственного положения;
- смешение похожих объектов;
- ошибка в цвете или другом атрибуте;
- выбор частого ответа при недостаточной уверенности;
- содержательно близкий, но формально отличающийся ответ;
- неправильный ответ на сложный вопрос, включающий несколько объектов.

Часть ошибок связана с ограничениями Exact Match. Например, правильный синоним или более подробный ответ мог считаться неправильным. Рост BERTScore после дообучения показывает, что некоторые ответы оставались семантически близкими к эталону даже при отсутствии точного совпадения.

5.10. Выбор итоговых моделей

По результатам экспериментов невозможно выбрать одну модель, которая была бы безусловно лучшей по всем показателям.

Qwen2.5-VL с LoRA №2 показала лучший результат на основной задаче проекта - формировании коротких открытых ответов на GQA-ru. Она получила:

- Exact Match - 0,5372;
- BERTScore F1 - 0,9065;
- Accuracy на MMBench-ru - 0,8033.

Qwen2.5-VL с LoRA №3 показала немного более низкий результат на GQA-ru, но стала лучшей на MMBench-ru:

- Exact Match - 0,5352;
- BERTScore F1 - 0,9055;
- Accuracy на MMBench-ru - 0,8061.

Если основным критерием является качество коротких русскоязычных ответов, предпочтительной является LoRA №2. Она немного точнее на GQA-ru и требует меньше времени на обучение.

Если приоритетом является результат на заданиях с вариантами ответа, лучшим вариантом является LoRA №3. Однако её преимущество на MMBench-ru невелико и не компенсирует дополнительные вычислительные затраты однозначно.

Поэтому обе конфигурации были сохранены как итоговые и опубликованы отдельно. Это позволяет выбирать модель в зависимости от предполагаемого сценария применения.

5.11. Основные выводы экспериментов

Проведённые эксперименты позволяют сделать следующие выводы.

Во-первых, метод LoRA оказался эффективным для адаптации Qwen2.5-VL к русскоязычной задаче Visual Question Answering. Лучший вариант повысил Exact Match на GQA-ru с 0,3198 до 0,5372.

Во-вторых, увеличение обучающей выборки с 5 000 до 20 000 примеров повысило качество. Однако дальнейшее увеличение до 30 000 примеров не привело к улучшению GQA-ru.

В-третьих, снижение функции потерь на обучающих данных не гарантировало более высокого результата на оценочном наборе. Поэтому выбор итоговой конфигурации должен выполняться по независимым метрикам, а не по результатам обучения.

В-четвёртых, эффект дообучения оказался значительно сильнее на GQA-ru, чем на MMBench-ru. Это говорит о специализации моделей на формате обучающего набора.

В-пятых, Qwen2.5-VL заметно превзошла SmolVLM как до, так и после дообучения. Более компактная модель улучшила результат на GQA-ru, но не достигла качества Qwen2.5-VL и ухудшилась на MMBench-ru.

В-шестых, наиболее сложными для моделей остались пространственные отношения и задания, требующие более сложного анализа нескольких объектов.

В целом поставленная цель была достигнута: дообучение на открытых данных VK позволило существенно повысить качество русскоязычных ответов Qwen2.5-VL и получить две итоговые конфигурации с разными преимуществами на GQA-ru и MMBench-ru.

Глава 6. Реализация и публикация решения

6.1. Общая структура реализации

Решение было реализовано как последовательный процесс, включающий подготовку данных, загрузку базовых моделей, дообучение методом LoRA, проведение инференса, расчёт метрик и публикацию итоговых моделей.

Работа над проектом была разделена на несколько этапов:

- подготовка и анализ наборов данных GQA-ru и MMBench-ru;
- получение предсказаний базовых моделей;
- дообучение моделей Qwen2.5-VL и SmolVLM;
- сохранение промежуточных состояний моделей;
- полная оценка всех конфигураций;
- расчёт общих метрик и показателей по категориям;
- объединение LoRA-адаптеров с базовыми моделями;
- публикация исходного кода, результатов и итоговых весов.

Разделение процесса на самостоятельные этапы позволило повторно запускать отдельные части проекта без необходимости полностью воспроизводить

обучение и инференс. Например, расчёт метрик можно было повторить на уже сохранённых предсказаниях, не загружая модели повторно.

Структура репозитория включает материалы для анализа данных, обучения, оценки, объединения моделей и хранения итоговых результатов. Отдельно сохраняются предсказания моделей, агрегированные метрики и результаты анализа по категориям.

6.2. Используемые программные средства

Основная реализация выполнена на языке Python. Для работы с нейронными сетями и проведения вычислений использовалась библиотека PyTorch.

Загрузка и запуск визуально-языковых моделей выполнялись с помощью библиотеки Transformers. Она использовалась для получения архитектур моделей, процессоров, токенизаторов и средств генерации ответов.

Для параметрически эффективного дообучения применялась библиотека PEFT. Она позволила подключить LoRA-адаптеры к выбранным слоям моделей, сохранить только обучаемые параметры и впоследствии объединить их с базовыми весами.

Для загрузки и обработки наборов данных применялась библиотека Datasets. Табличные результаты обрабатывались с помощью Pandas. Для отображения прогресса длительных операций использовалась библиотека tqdm.

Дополнительно применялись следующие средства:

- BERTScore - для расчёта семантической близости ответов;
- MLflow - для регистрации параметров и метрик экспериментов;
- DagsHub - для хранения и просмотра журналов MLflow;
- Hugging Face Hub - для публикации итоговых моделей;
- Git и GitHub - для контроля версий и размещения проекта.

Такой набор инструментов позволил организовать полный цикл работы: от подготовки данных и обучения до сравнения моделей и публикации результата.

6.3. Вычислительная среда

Обучение и основная оценка моделей выполнялись локально на компьютере с операционной системой Windows 11 и видеокартой NVIDIA GeForce RTX 3080 с 12 ГБ видеопамяти.

Доступный объём видеопамяти накладывал ограничения на параметры обучения. В частности, использовался размер батча, равный одному примеру на устройство, а увеличение эффективного размера батча обеспечивалось накоплением градиента.

Для снижения потребления памяти также применялись вычисления пониженной точности и gradient checkpointing. Дополнительно ограничивались разрешение входных изображений и максимальная длина текстовой последовательности.

Использование LoRA позволило проводить обучение моделей с несколькими миллиардами параметров без необходимости изменять и хранить градиенты для всех весов. Благодаря этому эксперименты удалось выполнить на пользовательской видеокарте без использования вычислительного кластера.

6.4. Реализация обучения

На этапе обучения каждый пример преобразовывался в мультимодальный формат, включающий изображение, русскоязычный вопрос и эталонный ответ.

Модели передавалась инструкция отвечать на вопрос по изображению и не добавлять объяснений. Такой формат был выбран с учётом структуры GQA-ги, в котором большая часть эталонных ответов состоит из одного или нескольких слов.

Перед началом обучения загружалась базовая модель, после чего к выбранным слоям подключались LoRA-адаптеры. Основные веса модели оставались замороженными, а обновлялись только параметры адаптера.

Во время обучения отслеживалось изменение функции потерь. Через заданное количество шагов сохранялись промежуточные состояния, что позволяло восстановить процесс после возможного прерывания.

Для каждого запуска фиксировались:

- название базовой модели;
- количество обучающих примеров;
- параметры LoRA;
- скорость обучения;
- размер батча;
- число шагов накопления градиента;
- продолжительность обучения;
- итоговое значение функции потерь;
- расположение сохранённых весов.

Параметры и результаты запусков регистрировались в MLflow и отображались через DagsHub. Это позволило сравнивать конфигурации и сохранять историю экспериментов.

6.5. Реализация инференса и оценки

После обучения для каждой модели выполнялся инференс на GQA-ru и MMBench-ru.

Для GQA-ru модель получала изображение и вопрос, после чего формировала короткий текстовый ответ. Полученные ответы нормализовались и сравнивались с эталонными значениями.

Для MMBench-ru в запрос дополнительно включались варианты ответа. Модель должна была выбрать один из них. Из сгенерированного текста извлекалось буквенное обозначение выбранного варианта, которое затем сравнивалось с правильным ответом.

Поскольку полная оценка всех моделей занимала продолжительное время, предсказания периодически сохранялись на диск. При повторном запуске уже обработанные примеры пропускались. Это позволяло продолжать инференс после остановки программы и не повторять ранее выполненные вычисления.

Для каждого предсказания сохранялись:

- идентификатор примера;

- идентификатор изображения;
- вопрос;
- эталонный ответ;
- ответ модели;
- нормализованный ответ;
- признак правильности;
- категория вопроса;
- сообщение об ошибке при его наличии.

После окончания инференса проверялись полнота результатов, отсутствие повторяющихся идентификаторов и соответствие числа строк размеру оценочной выборки. Только после прохождения этих проверок рассчитывались итоговые метрики.

6.6. Хранение результатов

Результаты экспериментов сохранялись в виде таблиц CSV. Такой формат был выбран из-за простоты просмотра, обработки и повторного расчёта метрик.

В репозитории были размещены:

предсказания моделей на GQA-гу;

предсказания моделей на MMBench-гу;

общие таблицы метрик;

результаты по категориям вопросов;

сравнение базовых и дообученных моделей;

параметры проведённых запусков.

Крупные исходные данные и локальные веса моделей не добавлялись в GitHub. Они были исключены с помощью файла `.gitignore`. Аналогичным образом исключались токены доступа, служебные файлы, промежуточные checkpoint и другие локальные артефакты.

В репозитории сохранялись только те результаты, которые необходимы для проверки выводов проекта: итоговые метрики, полные предсказания, описание структуры решения и инструкции по воспроизведению.

6.7. Объединение LoRA с базовой моделью

По умолчанию LoRA-адаптер хранится отдельно от базовой модели. Для его использования необходимо сначала загрузить исходную модель, а затем подключить обученные параметры.

Для упрощения использования лучшие адаптеры были объединены с базовыми весами Qwen2.5-VL. После объединения получалась полная модель, которую можно загружать и применять без отдельного подключения PEFT.

Такой вариант публикации имеет несколько преимуществ:

- пользователю не требуется отдельно скачивать адаптер;
- снижается вероятность ошибки при выборе базовой модели;
- модель загружается стандартными средствами Transformers;
- обеспечивается более простой запуск инференса;
- сохраняются все изменения, полученные при дообучении.

В проекте были объединены и опубликованы две конфигурации:

- Qwen2.5-VL с LoRA №2, показавшая лучший результат на GQA-ru;
- Qwen2.5-VL с LoRA №3, показавшая лучший результат на MMBench-ru.

Несмотря на наличие слова LoRA в названиях опубликованных репозиториях, они содержат полные объединённые веса, а не только отдельные адаптеры.

6.8. Публикация проекта на GitHub

Исходный код, описание проекта и результаты экспериментов были размещены в публичном репозитории GitHub Dezhurn/vk-vision-language-vqa.

В репозитории представлены:

- описание цели и задач проекта;
- информация об используемых данных;

- описание моделей и конфигураций обучения;
- структура проекта;
- инструкции по установке зависимостей;
- порядок воспроизведения основных этапов;
- итоговые таблицы метрик;
- ссылки на опубликованные модели;
- ограничения проведённого исследования.

Описание проекта позволяет последовательно повторить подготовку данных, обучение, инференс и расчёт метрик. Также в репозитории указано расположение основных результатов и порядок запуска этапов.

Публикация проекта на GitHub соответствует требованиям проектной задачи VK, согласно которым результат может быть размещён в виде решения на GitHub или архива в Облаке Mail.

6.9. Публикация моделей на Hugging Face

Итоговые модели были опубликованы на платформе Hugging Face в репозиториях:

- `Dezurg/qwen2.5-v2-3b-gqa-ru-lora`;
- `Dezurg/qwen2.5-v3-3b-gqa-ru-lora`.

Первая модель соответствует конфигурации LoRA №2. Она была выбрана как лучшая модель для генерации коротких ответов на GQA-ru.

Вторая модель соответствует конфигурации LoRA №3. Она показала максимальную Ассурасу на MMBench-ru.

Для каждой модели были опубликованы веса, конфигурация и необходимые файлы процессора. Это позволяет загружать модели стандартными средствами библиотеки Transformers.

Публикация двух вариантов была выбрана вместо публикации только одной модели, поскольку эксперименты не выявили единственного лидера по всем метрикам. В зависимости от сценария использования пользователь может

выбрать конфигурацию, ориентированную на открытые короткие ответы или на задания с вариантами ответа.

6.10. Воспроизводимость решения

Для повышения воспроизводимости в проекте использовались фиксированные значения случайного состояния. Это позволяло повторно формировать одинаковые обучающие подвыборки.

Основные параметры обучения и инференса были вынесены в отдельные настройки и сохранены вместе с результатами. Для каждого эксперимента фиксировались используемая модель, объём данных и параметры LoRA.

Последовательность воспроизведения проекта включает:

- установку необходимых библиотек;
- загрузку базовых моделей;
- загрузку наборов GQA-ru и MMBench-ru;
- подготовку локальной структуры данных;
- обучение выбранной конфигурации;
- выполнение инференса;
- расчёт итоговых метрик;
- объединение LoRA с базовой моделью при необходимости.

Полная воспроизводимость обучения также зависит от доступного оборудования, версий библиотек и параметров обработки изображений. Однако опубликованные объединённые модели позволяют воспроизвести инференс и проверить основные результаты без повторного обучения.

6.11. Итоги реализации

В результате проекта был реализован полный процесс адаптации визуально-языковых моделей к русскоязычной задаче Visual Question Answering.

Решение включает:

- обработку открытых данных VK;
- дообучение моделей методом LoRA;

- сравнение нескольких конфигураций;
- полную оценку на двух бенчмарках;
- сохранение предсказаний и метрик;
- регистрацию экспериментов;
- объединение адаптеров с базовыми весами;
- публикацию кода и итоговых моделей.

Исходный код и материалы проекта размещены на GitHub, а лучшие модели опубликованы на Hugging Face. Это позволяет использовать полученные результаты для дальнейших экспериментов, повторной оценки и разработки прикладных решений на основе русскоязычного анализа изображений.

Заключение

В рамках проекта была разработана и исследована методика адаптации визуально-языковых моделей к задаче формирования коротких русскоязычных ответов по изображениям. Работа была выполнена на открытых данных VK из коллекции DeepVK и соответствовала требованиям проектного задания: были определены цель и задачи, проведено обучение моделей, выполнена оценка качества и опубликованы материалы с описанием решения.

В качестве базовых архитектур использовались модели Qwen2.5-VL-3B-Instruct и SmolVLM-Instruct. Для их адаптации применялся метод LoRA, который позволил дообучить модели при ограниченных вычислительных ресурсах без изменения всех исходных параметров. В ходе экспериментов были подготовлены три конфигурации Qwen2.5-VL и одна конфигурация SmolVLM, различавшиеся объёмом обучающей выборки и параметрами LoRA.

Итоговая оценка проводилась на полных доступных выборках GQA-ru и MMBench-ru. Лучший результат на GQA-ru показала модель Qwen2.5-VL с LoRA №2. Значение Exact Match составило 0,5372, а BERTScore F1 - 0,9065. Для сравнения, базовая Qwen2.5-VL получила Exact Match 0,3198 и BERTScore F1 0,8064. Таким образом, дообучение позволило повысить точность полного совпадения ответа на 21,74 процентного пункта.

На MMBench-ru наилучший результат показала конфигурация Qwen2.5-VL с LoRA №3. Её Accuracy составила 0,8061 против 0,7992 у базовой модели. При

этом прирост на MMBench-ru оказался значительно меньше, чем на GQA-ru. Это показывает, что дообучение в первую очередь адаптировало модель к русскоязычным вопросам и формату коротких открытых ответов, характерному для GQA-ru.

Эксперименты также показали, что увеличение объёма обучающих данных не всегда приводит к дальнейшему росту качества. Конфигурация, обученная на 20 000 примерах, немного превзошла более крупную конфигурацию на GQA-ru, несмотря на меньшие вычислительные затраты. Поэтому итоговый выбор модели необходимо выполнять на основании независимой оценки, а не только размера обучающей выборки или значения функции потерь.

Дообучение SmolVLM также повысило качество на GQA-ru, однако модель осталась слабее Qwen2.5-VL. Это подтверждает, что результат зависит не только от метода адаптации, но и от возможностей исходной архитектуры.

В результате поставленная цель была достигнута. Метод LoRA позволил существенно улучшить качество Qwen2.5-VL на русскоязычной задаче Visual Question Answering. Были получены две итоговые модели: одна показывает наилучший результат при генерации коротких открытых ответов, а другая - при выполнении заданий с вариантами ответа.

Исходный код, описание экспериментов, предсказания и итоговые метрики опубликованы в открытом GitHub-репозитории. Лучшие модели объединены с базовыми весами и размещены на платформе Hugging Face, благодаря чему их можно использовать без отдельного подключения LoRA-адаптера.

В дальнейшем проект может быть расширен за счёт увеличения разнообразия обучающих данных, более точного подбора гиперпараметров, применения QLoRA, обучения в течение нескольких эпох и проверки моделей на дополнительных русскоязычных мультимодальных бенчмарках. Отдельным направлением развития является улучшение качества на вопросах о пространственных отношениях и заданиях, требующих анализа нескольких объектов.

Использованные источники

1. Коллекция DeepVK Vision-Language Modeling.
<https://huggingface.co/collections/deepvk/vision-language-modeling-664dd7e4c257cc78e740f6bc>
2. Набор данных DeepVK GQA-ru.
<https://huggingface.co/datasets/deepvk/GQA-ru>
3. Набор данных DeepVK MMBench-ru.
<https://huggingface.co/datasets/deepvk/MMBench-ru>
4. Базовая модель Qwen2.5-VL-3B-Instruct.
<https://huggingface.co/Qwen/Qwen2.5-VL-3B-Instruct>
5. Базовая модель SmolVLM-Instruct.
<https://huggingface.co/HuggingFaceTB/SmolVLM-Instruct>
6. Обзор визуально-языковых моделей Vision Language Models Explained.
<https://huggingface.co/blog/vlms>
7. Документация библиотеки Transformers.
<https://huggingface.co/docs/transformers>
8. Документация библиотеки PEFT и метода LoRA.
<https://huggingface.co/docs/peft>
9. Статья LoRA: Low-Rank Adaptation of Large Language Models.
<https://arxiv.org/abs/2106.09685>
10. Документация PyTorch.
<https://pytorch.org/docs/stable/index.html>
11. Документация MLflow.
<https://mlflow.org/docs/latest>
12. Платформа DagsHub.
<https://dagshub.com>
13. Документация BERTScore.
https://github.com/Tiiiger/bert_score

Артефакты проекта

1. Репозиторий проекта на GitHub.
<https://github.com/Dezurn/vk-vision-language-vqa>

2. Итоговая модель Qwen2.5-VL с LoRA №2. Модель показала лучший результат на GQA-ru.
<https://huggingface.co/Dezurg/qwen2.5-v2-3b-gqa-ru-lora>
3. Итоговая модель Qwen2.5-VL с LoRA №3. Модель показала лучший результат на MMBench-ru.
<https://huggingface.co/Dezurg/qwen2.5-v3-3b-gqa-ru-lora>
4. Итоговые метрики моделей на GQA-ru.
https://github.com/Dezurn/vk-vision-language-vqa/blob/main/reports/evaluation/all_models/gqa_metrics.csv
5. Итоговые метрики моделей на MMBench-ru.
https://github.com/Dezurn/vk-vision-language-vqa/blob/main/reports/evaluation/all_models/mmbench_metrics.csv